



Университет ИТМО

Факультет ИТиП

Группа М3232

Лабораторная работа №5

Задача регрессии

Дисциплина: Методы оптимизации

Выполнили:
Дегтярев Александр Сергеевич
Надточий Ярослав Вадимович

Проверила: Матвеева М.В.

Содержание

1	Постановка задачи	2
2	Теоретические основы	3
2.1	Задача наименьших квадратов	3
2.2	Проблема обусловленности	3
2.3	Переобучение и регуляризация	3
3	Описание методов оптимизации	3
3.1	Аналитическое решение	3
3.2	SGD и Mini-batch GD	4
3.3	Метод Гаусса–Ньютона	4
3.4	Метод Левенберга–Марквардта	4
4	Результаты	5
4.1	Наборы данных	5
4.2	Базовые модели: сравнение методов оптимизации	5
4.2.1	Набор данных «almost_linear»	5
4.2.2	Набор данных «nonlinear»	6
4.2.3	Примеры аппроксимации	7
4.3	Влияние размера батча	7
4.4	Регуляризация	9
4.5	Gauss-Newton vs Levenberg-Marquardt на плохо обусловленной задаче	11
5	Сравнение методов	12
6	Выводы	12

1 Постановка задачи

Исследуется задача восстановления регрессионной зависимости по зашумлённым данным. Данные генерируются на основе аналитических функций:

$$y_i = f_{\text{true}}(x_i) + \xi_i, \quad \xi_i \sim \mathcal{N}(0, \sigma^2).$$

Наборы данных

Сгенерированы два набора по $m = 150$ точек каждый:

1. **Почти линейная зависимость** (almost_linear):

$$f_{\text{true}}(x) = 2x - 1 + 0.1 \sin(4x), \quad x \in [-3, 3], \quad \sigma = 0.25.$$

2. **Сильно нелинейная зависимость** (nonlinear):

$$f_{\text{true}}(x) = 0.5x^3 - x + \sin(3x) + 2 \exp(-10(x-1)^2), \quad x \in [-2, 2], \quad \sigma = 0.3.$$

Модели регрессии

Полиномиальная регрессия степеней $p \in \{1, 2, 3, 4, 5\}$. Для $p = 1$ — линейная регрессия. Матрица признаков Φ содержит мономы $1, x, x^2, \dots, x^p$. Входной признак x нормализуется перед построением степеней для уменьшения числа обусловленности.

Функции потерь

Эмпирический риск (MSE) и четыре варианта функции потерь:

$$\mathcal{L}(w) = \underbrace{\frac{1}{m} \sum_{i=1}^m (\hat{y}_i - y_i)^2}_{Q(w)} + \lambda_1 \|w\|_1 + \lambda_2 \|w\|_2^2,$$

где $\hat{y}_i = \Phi_i w$. Варианты: без регуляризации ($\lambda_1 = \lambda_2 = 0$), L1 ($\lambda_1 > 0$), L2 ($\lambda_2 > 0$), Elastic Net ($\lambda_1, \lambda_2 > 0$). Для свободного коэффициента регуляризация не применяется.

Оптимизаторы

1. Аналитическое решение задачи линейной регрессии через оценки средних (для $p = 1$);
2. Стохастический градиентный спуск (SGD, batch_size = 1);
3. Mini-batch градиентный спуск (batch_size = 32);
4. Метод Гаусса-Ньютона;
5. Метод Гаусса-Ньютона с регуляризацией Левенберга-Марквардта.

Для каждого метода сохраняется история значений функции потерь, эмпирического риска и регуляризационных слагаемых. Для SGD и mini-batch фиксируются размер batch, число эпох и правило выбора шага.

2 Теоретические основы

2.1 Задача наименьших квадратов

Полиномиальная регрессия сводится к задаче наименьших квадратов: для матрицы признаков $\Phi \in \mathbb{R}^{m \times (p+1)}$ и вектора наблюдений $y \in \mathbb{R}^m$ найти вектор коэффициентов w , минимизирующий $Q(w) = \frac{1}{m} \|\Phi w - y\|^2$. Приравняв градиент к нулю, получаем нормальные уравнения $\Phi^T \Phi w = \Phi^T y$. Решение единственно, когда $\Phi^T \Phi$ обратима (столбцы Φ линейно независимы).

2.2 Проблема обусловленности

Матрица Φ содержит столбцы $1, x, x^2, \dots, x^p$. При больших p столбцы становятся почти линейно зависимыми, и число обусловленности $\kappa(\Phi^T \Phi)$ растёт экспоненциально. Например, при $p = 10$ без нормализации $\kappa \sim 3 \cdot 10^7$. Большое κ означает:

- малые изменения в данных вызывают большие изменения в w ;
- итеративные методы сходятся медленно;
- решение нормальных уравнений теряет точность из-за ошибок округления.

Нормализация каждого столбца Φ к нулевому среднему и единичной дисперсии уменьшает κ на порядки, стабилизируя все методы.

2.3 Переобучение и регуляризация

При высокой степени p полином имеет $p + 1$ параметров и может точно пройти через шумные точки, «запоминая» шум вместо истинной зависимости. Это *переобучение*: MSE на обучающей выборке мало, но модель плохо обобщается.

Регуляризация добавляет штраф на величину коэффициентов, вынуждая модель выбирать «простые» решения:

- **L1 (Lasso):** $\lambda_1 \sum |w_j|$. Штраф пропорционален абсолютным значениям. Геометрически — область допустимых w имеет «углы» на осях, поэтому оптимальное решение часто лежит на оси (некоторые $w_j = 0$). Это обеспечивает *разреженность* — автоматический отбор признаков.
- **L2 (Ridge):** $\lambda_2 \sum w_j^2$. Штраф пропорционален квадратам. Область допустимых w — шар, решение не обнуляет коэффициенты, а равномерно уменьшает их. L2 также улучшает обусловленность: $\Phi^T \Phi + m\lambda_2 I$ всегда обратима.
- **ElasticNet:** комбинация $\lambda_1 \|w\|_1 + \lambda_2 \|w\|_2^2$. Сочетает разреженность L1 и стабильность L2.

Свободный член (intercept w_0) не регуляризуется, чтобы не смещать среднее предсказание.

3 Описание методов оптимизации

3.1 Аналитическое решение

Для линейной регрессии ($p = 1$) минимум MSE достигается в замкнутой форме:

$$a = \frac{\sum (x_i - \bar{x})(y_i - \bar{y})}{\sum (x_i - \bar{x})^2}, \quad b = \bar{y} - a\bar{x}.$$

Это частный случай решения нормальных уравнений $\Phi^T \Phi w = \Phi^T y$ при $p = 1$. Вычисление стоит $O(m)$ и не требует итераций.

3.2 SGD и Mini-batch GD

Идея. Вместо вычисления полного градиента по всем m точкам, на каждом шаге используем подмножество (*мини-батч*) $B \subset \{1, \dots, m\}$:

$$\nabla_w \mathcal{L} \approx \frac{2}{|B|} \Phi_B^T (\Phi_B w - y_B) + \lambda_1 \cdot \text{sign}(w) + 2\lambda_2 w.$$

При $|B| = 1$ (SGD) градиент максимально шумный, но обновления максимально частые. При $|B| = m$ (полный GD) градиент точный, но дорогой.

L1 градиент. Функция $|w_j|$ недифференцируема в нуле. Используется smoothed аппроксимация: $\text{sign}(w_j) \approx w_j / \sqrt{w_j^2 + \varepsilon}$, $\varepsilon = 10^{-8}$, что обеспечивает непрерывный градиент.

Скорость обучения убывает: $\alpha_t = \alpha_0 / (1 + \gamma t)$, где γ — коэффициент затухания. Убывание необходимо для сходимости: постоянный шаг не позволяет SGD сойтись к точному минимуму (только колеблется вблизи).

Gradient clipping. Если $\|\nabla\| > 100$, градиент масштабируется: $\nabla \leftarrow \nabla \cdot 100 / \|\nabla\|$. Это предотвращает «взрыв» обновлений при плохой обусловленности.

3.3 Метод Гаусса–Ньютона

Идея. Специализированный метод Ньютона для задачи наименьших квадратов. В общем методе Ньютона нужен полный гессиан $\nabla^2 \mathcal{L}$, который содержит члены с вторыми производными r_i . Гаусс–Ньютон аппроксимирует гессиан как $\frac{2}{m} \Phi^T \Phi$, отбрасывая члены второго порядка. Для линейной регрессии эта аппроксимация точна (вторые производные r_i равны нулю), поэтому метод находит оптимум за 1 шаг.

Итерация решает систему нормальных уравнений:

$$(\Phi^T \Phi + m\lambda_2 R) h = -\Phi^T r - m\lambda_2 R w,$$

где $r = \Phi w - y$ — вектор невязок, R — диагональная матрица регуляризации (нулевой элемент для свободного члена).

Сложность итерации: $O(n^2 m)$ для формирования $\Phi^T \Phi$ и $O(n^3)$ для решения системы. При $m \gg n$ (150 точек, $p \leq 10$) это дешево. Сходимость квадратичная вблизи решения.

Ограничение. Если $\Phi^T \Phi$ плохо обусловлена, решение системы теряет точность.

3.4 Метод Левенберга–Марквардта

Идея. Добавляет демпфирующий член μI к матрице нормальных уравнений:

$$(\Phi^T \Phi + m\lambda_2 R + \mu I) h = -\Phi^T r - m\lambda_2 R w.$$

Интерпретация. При $\mu \rightarrow 0$ метод совпадает с Гаусс–Ньютоном (быстрая локальная сходимость). При $\mu \rightarrow \infty$ шаг $h \approx -\frac{1}{\mu} g$ — малый шаг в направлении антиградиента (медленная, но гарантированная сходимость). Таким образом, ЛМ интерполирует между двумя методами.

Адаптация μ . При успешном шаге (функция уменьшилась): $\mu \rightarrow \mu/2$ — доверяем модели, переходим ближе к Гаусс–Ньютону. При неудачном: $\mu \rightarrow 2\mu$ — уменьшаем шаг, переходим ближе к градиентному спуску. Начальное $\mu_0 = 0.01$.

Преимущество. $\Phi^T \Phi + \mu I$ всегда обратима при $\mu > 0$, даже если $\Phi^T \Phi$ вырождена. Это делает ЛМ устойчивым к плохой обусловленности.

4 Результаты

4.1 Наборы данных




Рис. 1: Наборы данных: почти линейный (слева) и нелинейный (справа)

4.2 Базовые модели: сравнение методов оптимизации

Зачем этот эксперимент. Сравниваем все методы оптимизации на одних и тех же данных и моделях. Для каждой пары «набор данных + степень полинома» запускаем все доступные методы и сравниваем: (a) итоговое MSE (качество аппроксимации), (b) число итераций/эпох, (c) число вычислений градиента, (d) время работы. Ожидаем, что методы второго порядка (GN, LM) сойдутся за единицы итераций, а стохастические (SGD, mini-batch) — будут приближаться к оптимуму, но не достигнут его за ограниченное число эпох.

4.2.1 Набор данных «almost_linear»

Таблица 1: Результаты на наборе almost_linear

Степень	Метод	MSE	Итер./эпохи	∇f -выч.	Время, с	Статус
1	Analytic	0.0812	1	0	0.00004	closed_form
	SGD	0.0812	360	54000	0.707	max_epochs
	Mini-batch	0.0812	360	1800	0.042	max_epochs
	Gauss-Newton	0.0812	2	2	0.0003	converged
	Lev.-Marq.	0.0812	4	4	0.0004	converged
3	SGD	0.0830	360	54000	1.164	max_epochs
	Mini-batch	0.0816	360	1800	0.062	max_epochs
	Gauss-Newton	0.0803	2	2	0.0003	converged
	Lev.-Marq.	0.0803	6	6	0.0006	converged
5	SGD	0.0831	360	54000	0.717	max_epochs
	Mini-batch	0.1080	360	1800	0.040	max_epochs
	Gauss-Newton	0.0791	2	2	0.0002	converged
	Lev.-Marq.	0.0791	6	6	0.0004	converged

4.2.2 Набор данных «nonlinear»

Таблица 2: Результаты на наборе nonlinear

Степень	Метод	MSE	Итер./эпохи	∇f -выч.	Время, с	Статус
1	Analytic	0.6916	1	0	0.00003	closed_form
	SGD	0.6917	360	54000	0.707	max_epochs
	Mini-batch	0.6916	360	1800	0.035	max_epochs
	Gauss-Newton	0.6916	2	2	0.0001	converged
	Lev.-Marq.	0.6916	4	4	0.0003	converged
3	SGD	0.6940	360	54000	0.723	max_epochs
	Mini-batch	0.6857	360	1800	0.035	max_epochs
	Gauss-Newton	0.6857	2	2	0.0001	converged
	Lev.-Marq.	0.6857	5	5	0.0004	converged
5	SGD	0.2390	360	54000	0.712	max_epochs
	Mini-batch	0.3669	360	1800	0.036	max_epochs
	Gauss-Newton	0.2247	2	2	0.0001	converged
	Lev.-Marq.	0.2247	7	7	0.0005	converged

Gauss-Newton сходится за 2 итерации для всех степеней и наборов данных. Levenberg-Marquardt требует 4–25 итераций. SGD и mini-batch не сходятся за 360 эпох, но при малых степенях достигают близких значений MSE.




Рис. 2: Сравнение методов: динамика потерь для степени 5

4.2.3 Примеры аппроксимации




Рис. 3: Аппроксимация нелинейного набора: степень 1 (слева) и степень 5 (справа), Gauss-Newton




Рис. 4: Аппроксимация линейного набора: степень 1 аналитически (слева) и степень 5 Gauss-Newton (справа)

4.3 Влияние размера батча

Зачем этот эксперимент. Размер батча $|B|$ — ключевой гиперпараметр стохастических методов. Он определяет компромисс:

- Малый батч — больше обновлений за эпоху, но каждое зашумлено (дисперсия градиента $\sim 1/|B|$). Шум помогает «выбираться» из плохих областей, но замедляет финальную сходимость.
- Большой батч — точный градиент, но мало обновлений за эпоху. При фиксированном бюджете эпох модель получает меньше «опыта».

Задание требует сравнить размеры 1, 4, 8, 16, 32, 64, 150 ($\approx m$) по скорости сходимости, стабильности и вычислительной эффективности.

Эксперимент на наборе «nonlinear» со степенью 5 (достаточно сложная модель для проявления различий). Все конфигурации использовали 480 эпох.

Таблица 3: Влияние размера батча на качество (nonlinear, степень 5)

Batch size	MSE	∇f -выч.	Время, с
1	0.2566	72 000	0.936
4	0.2291	18 240	0.250
8	0.2332	9120	0.136
16	0.2707	4800	0.081
32	0.3589	2400	0.048
64	0.4331	1440	0.035
150	0.5517	480	0.037

Малые батчи (4–8) достигают лучшего MSE, но требуют больше вычислений градиента. Большие батчи (64–150) быстрее, но не успевают сойтись за ограниченное число эпох. Оптимальный баланс — `batch_size = 4` (MSE = 0.229 при 18 240 вычислениях градиента).




Рис. 5: Потери по эпохам для разных размеров батча




Рис. 6: Потери по числу вычислений градиента для разных размеров батча

4.4 Регуляризация

Зачем этот эксперимент. Полином степени 10 имеет 11 параметров на 150 точек — модель достаточно гибкая для переобучения. Без регуляризации полином может «колебаться» между точками, давая большие значения вне данных. Задание требует:

- для L1, L2 и Elastic Net рассмотреть несколько значений λ ;
- построить графики динамики полного loss, эмпирического риска и регуляризационных слагаемых;
- сравнить коэффициенты моделей до и после регуляризации;
- сделать вывод о влиянии разных типов регуляризации на качество и структуру модели.

Эксперимент на наборе «nonlinear» со степенью 10 (mini-batch GD, batch_size = 32, 1000 эпох).

Таблица 4: Влияние регуляризации (степень 10, nonlinear)

Тип	λ	Loss	MSE (risk)	L1-штраф	L2-штраф	Clipped
none	—	0.4006	0.4006	0	0	727
L1	10^{-4}	0.4000	0.3998	0.00012	0	696
L1	10^{-3}	0.3974	0.3962	0.00125	0	705
L1	10^{-2}	0.4218	0.4110	0.01084	0	722
L1	10^{-1}	0.5292	0.4570	0.07224	0	756
L2	10^{-4}	0.3993	0.3992	0	0.00002	686
L2	10^{-3}	0.3993	0.3991	0	0.00019	716
L2	10^{-2}	0.4105	0.4088	0	0.00174	727
L2	10^{-1}	0.4472	0.4303	0	0.01689	766
ElasticNet	10^{-3}	0.4048	0.4034	0.00119	0.00018	715
ElasticNet	10^{-1}	0.5166	0.4404	0.06875	0.00744	700

Лучший MSE (0.396) достигается при L1 с $\lambda_1 = 10^{-3}$. Слишком сильная регуляризация ($\lambda = 0.1$) приводит к underfitting. L2 с малыми λ мало влияет на MSE, но стабилизирует обучение.




Рис. 7: Аппроксимация при разных типах регуляризации




Рис. 8: Коэффициенты полинома при разных типах регуляризации




Рис. 9: Компоненты потерь: без регуляризации (слева) и L1 $\lambda = 10^{-3}$ (справа)




Рис. 10: Компоненты потерь: L2 $\lambda = 10^{-2}$ (слева) и ElasticNet $\lambda = 10^{-1}$ (справа)

4.5 Gauss-Newton vs Levenberg-Marquardt на плохо обусловленной задаче

Зачем этот эксперимент. Задание требует отдельно сравнить GN и LM на нелинейной или плохо обусловленной постановке. При степени 10 без нормализации признаков число обусловленности $\kappa(\Phi^T \Phi) \sim 3 \cdot 10^7$, что делает решение нормальных уравнений численно нестабильным. Gauss-Newton может «промахнуться» из-за ошибок округления, а Levenberg-Marquardt остаётся устойчивым: демпфирование μI регуляризует матрицу, обеспечивая $\kappa(\Phi^T \Phi + \mu I) \leq \kappa(\Phi^T \Phi) / \mu \cdot \lambda_{\min}$.




Рис. 11: GN vs LM: потери на плохо обусловленной задаче (степень 10, без нормализации)

5 Сравнение методов

Таблица 5: Сравнительная характеристика методов оптимизации для регрессии

Метод	Итер. до сход.	Сложность итерации	Особенности
Analytic	1	$O(n^2m)$	только степень 1
SGD	>360	$O(n)$	шумная сходимость
Mini-batch	>360	$O(Bn)$	баланс скорость/шум
Gauss-Newton	2	$O(n^2m + n^3)$	требует $\Phi^T \Phi$ обратима
Lev.-Marq.	4–25	$O(n^2m + n^3)$	устойчивее GN

6 Выводы

Сравнение методов оптимизации

1. **Gauss-Newton** — безусловный лидер по скорости сходимости: 2 итерации для любой степени полинома при нормализованных признаках. Для линейных наименьших квадратов задача решается точно за один шаг решения нормальных уравнений.
2. **Levenberg-Marquardt** сходится за 4–7 итераций в большинстве случаев. На нелинейном наборе при степени 4 LM потребовал 25 итераций (18 отклонённых шагов), что связано с плохой начальной точкой и необходимостью увеличения μ до 40.96. На ненормализованных признаках степени 10 LM стабильно работает благодаря демпфированию μI .
3. **SGD и mini-batch GD** не сходятся за 360 эпох, но достигают приемлемых значений MSE при малых степенях. При степени 5 на нелинейном наборе SGD (MSE = 0.239) приближается к оптимуму Gauss-Newton (0.225), тогда как mini-batch с batch_size = 32 значительно отстаёт (MSE = 0.367).

Медленная сходимость и чувствительность

- **SGD при высоких степенях** демонстрирует медленную сходимость: при степени 5 на наборе `almost_linear` происходит 578 обрезаков градиента (`gradient clipping`), что указывает на нестабильность обновлений. Число обусловленности матрицы признаков при степени 5 составляет ~ 1390 .
- **Mini-batch при больших `batch_size`**: при `batch_size = 150` (почти полный GD) за 480 эпох достигается $\text{MSE} = 0.552$ vs 0.229 при `batch_size = 4`. Крупные батчи медленнее исследуют пространство параметров, т.к. делают меньше обновлений за эпоху.
- **Gauss-Newton на плохо обусловленной задаче**: без нормализации число обусловленности $\Phi^T \Phi$ при степени 10 составляет $\sim 3 \cdot 10^7$, что приводит к потере точности при решении системы нормальных уравнений.

Влияние регуляризации на структуру коэффициентов

- **L1** ($\lambda = 10^{-3}$) улучшает MSE с 0.401 до 0.396 при степени 10 за счёт обнуления шумных коэффициентов высоких степеней. При $\lambda = 0.1$ коэффициенты w_4, w_7 практически обнуляются ($\sim 10^{-4}$), но наступает `underfitting` ($\text{MSE} = 0.457$).
- **L2** уменьшает абсолютные значения всех коэффициентов равномерно, не создавая разреженности. При $\lambda = 10^{-4}$ влияние минимально ($\text{L2-штраф} = 2 \cdot 10^{-5}$).
- **ElasticNet** комбинирует свойства L1 и L2: при $\lambda_1 = \lambda_2 = 0.1$ коэффициенты уменьшены и частично обнулены ($\text{MSE} = 0.440$).

Нормализация признаков

Нормализация критически важна: число обусловленности матрицы Φ при степени 10 составляет $\sim 3 \cdot 10^7$. Без нормализации стохастические методы нестабильны, а Gauss-Newton теряет точность при решении нормальных уравнений. Levenberg-Marquardt устойчивее благодаря регуляризующему эффекту демпфирования.